



数理统计笔记

作者：肖程哲

时间：January 14, 2023



苟日新，日日新，又日新

目录

第 1 章 导论: 从数据中学习	1	3.3.4 Cramer-Rao 不等式	19
1.1 统计模型	1	第 3 章 练习	20
1.2 统计量	2		
第 1 章 练习	3	第 4 章 区间估计	21
		4.1 区间估计的概念	21
第 2 章 抽样分布	4	4.2 枢轴变量法	21
2.1 统计量的极限分布	4	4.2.1 正态总体参数	21
2.2 指数族	4	4.2.2 非正态总体参数	21
2.3 充分统计量	4	4.3 Fisher 的信仰推断法	21
2.4 完全统计量	5	4.4 容忍区间于容忍限	21
第 3 章 点估计	6	第 4 章 练习	21
3.1 点估计的评价方法	6	第 5 章 假设检验	22
3.1.1 无偏性	6	5.1 假设检验的概念	22
3.1.2 有效性	7	5.1.1 基本思想	22
3.1.3 均方误差	8	5.1.2 Neyman-Pearson 范式 .	23
3.1.4 相合性	9	5.2 正态总体参数假设检验	23
3.1.5 渐近正态性	10	5.3 然似比检验	23
3.2 点估计的方法	11	5.4 一致最优检验	23
3.2.1 矩估计	11	5.5 无偏检验	23
3.2.2 极大然似估计	12	5.6 假设检验与区间估计	23
3.2.3 贝叶斯估计	13	第 5 章 练习	23
3.2.4 最小二乘估计	15	第 6 章 线性模型	24
3.3 最小方差无偏估计	15	6.1 回归分析	24
3.3.1 最小方差无偏估计	15	6.2 最小二乘法	24
3.3.2 充分性原则	16	6.3 方差分析	24
3.3.3 费希尔信息量	17		

第 1 章 导论：从数据中学习

统计学的主要研究内容是如何收集和处理随机数据。数据的随机性一方面来源于自然物理机制中不可避免的随机性；一方面来源于不能被控制（或者不关心）的其他因素。收集数据时，应尽量使其具有代表性（常通过分层抽样实现）。从数据中获取信息，并借此解释和预测数据的过程称为推断（inference）。统计推断基于概率模型，对两个基本问题：估计（estimation）与检验（testing）进行回答。为了有效地使用数据进行统计推断，需要给定某些准则去评判不同统计推断方法的优劣。

1.1 统计模型

定义 1.1 (样本)

在实验中获取的观测值 $\mathbf{x} = (x_1, \dots, x_n)$ 视为某个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机元 X 的实现（realization）。概率测度 \mathbb{P} 称为总体，观测值或其对应的随机元称为样本（sample），这组观测值的数目 n 称为样本容量（sample size）。



定义 1.2 (总体)

假设样本来源于各分量 X_i 独立同分布的随机向量，其分布 $P(\bullet) := \mathbb{P}\{X_i \in \bullet\}$ 称为总体（population）。



在统计学中可以认为总体 P 包含我们想知道的一切信息，然而（至少部分）是未知的。我们希望用样本 \mathbf{x} 推断总体 P 的性质。

定义 1.3 (参数)

在总体中固定但未知的常数称为参数，记为 θ 。参数所有可能的取值构成参数空间，记为 Θ ，可以是有限维或者无限维。



注 参数的函数同样固定且未知，故也视为参数。

定义 1.4 (统计模型)

统计模型（statistical model）是样本 \mathbf{X} 对应的所有可能的总体 P 的集合。在同一统计模型中，不同的总体通过参数区分，所以将模型记为：

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$$



统计模型代表关于数据产生机制的先验（prior）知识。

定义 1.5 (可识别)

若模型 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ 满足：

$$P_{\theta_1} \neq P_{\theta_2}, \forall \theta_1 \neq \theta_2$$

则称模型 \mathcal{P} 可识别 (identifiable) 

定义 1.6

若 Θ 有限维的，则称模型 \mathcal{P} 为参数族 (parametric family)；若参数空间 Θ 是无限维的，则称为非参数族。 

我们常常只关心参数 Θ 的某些分量的函数 $\gamma = g(\theta)$ ，剩下的碍事且无用的部分称为冗余参数 (nuisance parameter)。

1.2 统计量

定义 1.7 (统计量)

给定样本 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P$ ，其中 $P \in \mathcal{P}$ 是未知的总体。若 $T : (\mathcal{X}_n, \mathcal{F}_{\mathcal{X}}^n) \rightarrow (\mathcal{T}, \mathcal{F}_{\mathcal{T}})$ 是已知的 (不依赖 P 的) 可测函数，则称 $T(\mathbf{X}) = T(X_1, \dots, X_n)$ 为统计量 (statistic)。 

定义 1.8

统计量的分布称为它的抽样分布 (sampling distribution)，含有总体 (样本分布) 的一部分信息。 

统计量函数，不依赖未知总体，给出了一种数据约简 (reduction)。对于实数值样本 $x = \{x_1, \dots, x_n\}$ ，常见的统计量有：

样本均值 (sample mean)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

样本方差 (sample variance)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

由此可得样本标准差 (sample standard deviation) $s = \sqrt{s^2}$.

样本中位数 (sample median)

$$M = \text{med}(x) = \begin{cases} x_{(k)}, & n = 2k - 1 \\ \frac{1}{2}(x_{(k)} + x_{(k+1)}), & n = 2k \end{cases}$$

其中顺序统计量 $x_{(1)} \leq \dots \leq x_{(n)}$ 由 x_1, \dots, x_n 排列得到。

四分位数 (quartile)

$$Q_1 = \text{med}(x \cap (-\infty, M)), \quad Q_3 = \text{med}(x \cap (M, +\infty)).$$

四分位距 (inter quartile range)

$$IQR = Q_3 - Q_1.$$

极差 (range)

$$x_{(n)} - x_{(1)} = \max(x) - \min(x) = \max_{1 \leq i, i' \leq n} \{x_i - x_{i'}\}.$$

定义 1.9

五数概括法 (five-number summary): 以 $x_{(1)}, Q_1, M, Q_3, x_{(n)}$ 总结 x , 可用**箱形图** (boxplot) 表示.



错题记录

- (茆 5.5.10) 设 x_1, \dots, x_n 是来自正态分布 $N(\mu, \sigma^2)$ 的样本, 在 μ 已知时给出 σ^2 的一个充分统计量

第 2 章 抽样分布

2.1 统计量的极限分布

2.2 指数族

2.3 充分统计量

若样本数据量大，可能难以解释。试验者希望提取样本值的一些关键特征以概括样本中的信息。这类数据简化（缩减）在计算统计学中通常以样本函数的形式实现，例如，样本均值、样本方差、最大观测值和最小观测值就是四个概括样本关键特征的统计量。

任意一个统计量 $T(X)$ 都定义了一种数据简化方式。如果试验者只观测统计量 $T(x)$ 而非整个样本 x ，则他必将满足 $T(x) = T(y)$ 的 x 和 y 视作两个相同的样本，尽管事实可能并非如此。不同的统计量对数据中的信息划分有不同的方法。

依据某统计量简化样本数据可以看成样本空间 \mathcal{X} 上的一个划分。设 $\mathcal{T} = \{t | \exists x \in \mathcal{X}, \text{s.t. } t = T(x)\}$ 为 \mathcal{X} 在 $T(x)$ 下的象。则 $A_t = \{x | T(x) = t, t \in \mathcal{T}\}$ 为 \mathcal{X} 若干划分。

原始数据包含了所有信息，规律或随机部分。若进行转化，则将丢失信息，可能有用，也可能无用。其中界限由假设的统计模型判断。转化后的可能结果：

1. 留下部分有用信息：完备统计量
2. 留下所有有用信息：充分统计量
3. 不留下有用信息：辅助统计量

例题 2.1 设 $X_1, \dots, X_n \sim Binomial(p)$ i.i.d., 设 $T(X) = \sum X_i$ 。若 $T = t$ 已知，则实验结果与 p 无关，由于：

$$P(X|T) = \frac{P(X)}{P(T)} = \frac{\frac{p^t(1-p)^{n-t}}{\binom{n}{t} p^t(1-p)^{n-t}}}{\frac{1}{\binom{n}{t}}} = \frac{1}{\binom{n}{t}}$$

注 $T \sim Binomial(n, p)$ 与 p 有关，而 $X|T$ 与参数无关。即原始数据经 T 转化后的 $T(X)$ ，仍包含所有关于参数的信息；而余下的 $X|T$ 不再包含参数信息。

定义 2.1 (充分统计量)

假设样本 X ，满足分布 $P(\theta)$ ，若统计量 $S(X)$ ， $P(X|S)$ 与 θ 无关，则称 $S(X)$ 为关于 θ 的充分统计量。

注 充分统计量的判断与统计模型有关，模型不当可能导致充分统计量实际不“充分”。

定理 2.1 (分解定理)

$S(X)$ 为关于 θ 的充分统计量的充要条件为：

$$\exists g(\cdot), h(\cdot) \text{ s.t. } f(X|\theta) = g(S(X), \theta)h(X)$$



注 直观理解: $P(X) = P(S)P(X|S)$

证明 对于离散情况:

充分:

$$P(S=s) = \sum_{S(x)=s} P(X=x) = g(s, \theta) \sum_{S(x)=s} h(x)$$

$$P(X=x|S=s) = \frac{P(X=x)}{P(S=s)} = \frac{h(x)}{\sum_{S(x)=s} h(x)}$$

与 θ 无关。

必要:

令

$$g(s, \theta) = P(T=s|\theta), h(x) = P(X=x|S=s)$$

即可

定理 2.2

若 $S(X)$ 为关于 θ 的充分统计量，则 θ 的极 然似估计可表示为 S 的函数。



证明 然似函数为 $g(S, \theta)h(X)$ 。由于 $h(X)$ 为定值，故只需求 $g(S, \theta)$ 的极值情况，故 θ 的取值可由 S 的函数表示。

为使数据尽可能精简，摈弃无用信息，定义极小充分统计量。

定义 2.2 (极小充分统计量)

若统计量 M 满足

$$\forall S, \exists h \text{ s.t. } M = h(S)$$

则其为关于 θ 的充分统计量



2.4 完全统计量

第3章 点估计

考试重点

- 矩估计和极大似然估计
- 点估计的其他评价方法
- UMVUE
- (弱) 相合和强相合
- Fisher 信息量和有效估计
- 贝叶斯估计

定义 3.1 (点估计)

用于估计参数 $\gamma = g(\theta)$ 的统计量 $T(\mathbf{X})$ 称为估计量 (estimator), 记为 $\hat{\gamma} = T(\mathbf{X})$. 估计式是随机变量, 若给定统计模型, 则其分布由参数 θ 决定, 将观测数值代入估计式后得到的值称为估计值.



将数据代入估计式得到的估计值并不是真实的参数值, 若使用新的样本, 很可能会得到不同的估计值。

3.1 点估计的评价方法

3.1.1 无偏性

定义 3.2 (无偏估计)

估计式的偏差 (standard error) 定义为其抽样分布的均值与实际参数的偏差, 即:

$$E(\hat{\theta}) - \theta$$

若其为零, 则称此估计为参数 θ 的无偏估计



例题 3.1 方差的无偏估计

$$\begin{aligned}s^2 &= \frac{1}{n-1} \sum_{i=0}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left[\sum_{i=0}^n X_i^2 - n\bar{X}^2 \right] \\&= \frac{1}{n-1} \left[\sum_{i=0}^n X_i^2 - \frac{1}{n} (\sum_{i=0}^n X_i)^2 \right] = \frac{1}{n-1} \left[\sum_{i=0}^n X_i^2 - \frac{1}{n} (\sum_{i=0}^n X_i^2 + \sum_{i \neq j} X_i X_j) \right] \\&= \frac{1}{n} \sum_{i=0}^n X_i^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j \\E(s^2) &= \frac{1}{n} \sum_{i=0}^n E(X_i^2) - \frac{1}{n(n-1)} \sum_{i \neq j} E(X_i X_j) = \mu_2 - m_1^2 = \sigma^2\end{aligned}$$

定义 3.3 (渐进无偏估计)

若样本量趋于无穷时，估计式的偏差为零，即：

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$$

则称此估计为参数 θ 的渐近无偏估计



例题 3.2 样本方差的渐进无偏性 对于样本方差 $s_n^2 = \frac{1}{n} \sum_{i=0}^n (X_i - \bar{X})^2$, 其期望为 $E(s_n^2) = \frac{n-1}{n} \sigma^2$ 。当样本量趋于无穷时，有 $E(s^2) \rightarrow \sigma^2$ 。故 s^2 为 σ^2 的渐近无偏估计。

无偏性不具有不变性，即若 $\hat{\theta}$ 是 θ 的无偏估计，一般而言，其函数 $g(\hat{\theta})$ 不是 $g(\theta)$ 的无偏估计，除非 $g(\theta)$ 是 θ 的线性函数。譬如， s^2 是 σ^2 的无偏估计，但 s 不是 σ 的无偏估计。

例题 3.3 设总体为 $N(\mu, \sigma^2)$, x_1, \dots, x_n 是样本，考察 s 是否是 σ 的无偏估计。 $Y = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$, 其密度函数为

$$p(y) = \frac{1}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} y^{\frac{n-1}{2}-1} e^{-\frac{y}{2}}, \quad y > 0$$

从而

$$\begin{aligned} E(Y^{1/2}) &= \int_0^{+\infty} y^{1/2} p(y) dy = \frac{1}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} \int_0^{\infty} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} dy \\ &= \frac{2^{\frac{n}{2}} \Gamma(\frac{n}{2})}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} = \sqrt{2} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \end{aligned}$$

由此，我们有

$$E(s) = \frac{\sigma}{\sqrt{n-1}} E(Y^{1/2}) = \sqrt{\frac{2}{n-1}} \cdot \frac{\Gamma(n/2)}{\Gamma((n-1)/2)} \cdot \sigma$$

这说明 s 不是 σ 的无偏估计。

当参数存在无偏估计时，我们称该参数是可估的，否则称它是不可估的。

3.1.2 有效性

参数的无偏估计可以有很多，如何在无偏估计中进行选择？直观的想法是希望该估计围绕参数真值的波动越小越好，波动大小可以用方差来衡量，因此人们常用无偏估计的方差的大小作为度量无偏估计优劣的标准，这就是有效性。

定义 3.4 (有效性)

设 $\hat{\theta}_1, \hat{\theta}_2$ 是 θ 的两个无偏估计，如果对任意的 $\theta \in \Theta$ 有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

且至少有一个 $\theta \in \Theta$ 使得上述不等号严格成立，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。



3.1.3 均方误差

无偏性是估计的一个优良性质，对无偏估计我们还可以通过其方差进行有效性比较。然而不能由此认为：有偏估计一定是不好的估计。

在有些场合，有偏估计比无偏估计更优，这就涉及如何对有偏估计进行评价。一般而言，在样本量一定时，评价一个点估计的好坏使用的度量指标总是点估计值与参数真值 θ 的距离的函数，最常用的函数是距离的平方。由于具有随机性，可以对该函数求期望，

定义 3.5

估计式与参数的平方的期望称为**均方误差**

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2$$



注意到

$$\begin{aligned}\text{MSE}(\hat{\theta}) &= [E(\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)^2] \\ &= E(\hat{\theta} - E\hat{\theta})^2 + (E\hat{\theta} - \theta)^2 + 2E[(\hat{\theta} - E\hat{\theta})(E\hat{\theta} - \theta)] \\ &= \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2\end{aligned}$$

因此，均方误差由点估计的方差与偏差的平方两部分组成。如果 $\hat{\theta}$ 是 θ 的无偏估计，则 $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$ ，此时用均方误差评价点估计与用方差是一样的；当 $\hat{\theta}$ 不是 θ 的无偏估计时，就要看其均方误差 $\text{MSE}(\hat{\theta})$ ，即不仅要看其方差大小，还要看其偏差大小。

定义 3.6 (一致最小均方误差估计)

在一个估计类中，若其中的一个估计式 $\hat{\theta}$ 对估计类中任意一个估计式 $\tilde{\theta}$ ，在参数空间 Θ 上满足

$$\text{MSE}_{\theta}(\hat{\theta}) \leq \text{MSE}_{\theta}(\tilde{\theta}), \quad \forall \theta \in \Theta$$

则称此估计式为该估计类中 θ 的**一致最小均方误差估计**。



例题 3.4 对均匀总体 $U(0, \theta)$ ，考虑 θ 的形如 $\hat{\theta}_\alpha = \alpha \cdot x_{(n)}$ 的估计，其均方误差为

$$\begin{aligned}\text{MSE}(\hat{\theta}_\alpha) &= \text{Var}(\alpha \cdot x_{(n)}) + (\alpha E x_{(n)} - \theta)^2 \\ &= \alpha^2 \text{Var}(x_{(n)}) + \left(\alpha \frac{n}{n+1} \theta - \theta\right)^2 \\ &= \alpha^2 \frac{n}{(n+1)^2(n+2)} + \left(\frac{n \cdot \alpha}{n+1} - 1\right)^2 \theta^2.\end{aligned}$$

用求导的方法不难求出当 $\alpha_0 = (n+2)/(n+1)$ 时上述均方误差达到最小，此时 $\text{MSE}\left(\frac{n+2}{n+1} x_{(n)}\right) = \frac{\theta^2}{(n+1)^2}$ 。 $\hat{\theta}_0 = \frac{n+2}{n+1} x_{(n)}$ 虽是 θ 的有偏估计，但对于无偏估计 $\hat{\theta} = \frac{n+1}{n} x_{(n)}$ 而言，其均方误差 $\text{MSE}(\hat{\theta}_0) = \frac{\theta^2}{(n+1)^2} < \frac{\theta^2}{n(n+2)} = \text{MSE}(\hat{\theta})$ 。所以在均方误差的标准下，有偏估计 $\hat{\theta}_0$ 优于无偏估计 $\hat{\theta}$ 。并且 $\hat{\theta}_0$ 为形如 $\alpha \cdot x_{(n)}$ 的估计类中 θ 的一致最小均方误差估计。

若不对估计加以限制（即考虑所有可能的估计），则一致最小均方误差估计是不存在的，从而没有意义。事实上，若 $\hat{\theta}$ 是 θ 的所有估计中的一致最小均方误差估计，取定任一个 $\theta_0 \in$

Theta, 令 $\tilde{\theta} = \theta_0$, 则 $MSE_{\theta_0}(\tilde{\theta}) = 0$, 于是要求 $\hat{\theta}_0$ 也有 $MSE_{\theta_0}(\hat{\theta}) = 0$, 由 θ_0 的任意性, 这意味着 MSE_{θ} 处处为 0, 这显然是做不到的。

3.1.4 相合性

定义 3.7 (相合)

若当样本容量 $n \rightarrow \infty$ 时, 有

$$\hat{\gamma} \xrightarrow{\mathbb{P}} \gamma, \quad \forall \theta \in \Theta.$$

则称 $\hat{\gamma}$ 是相合的/一致的 (consistent), 如果上式中 $\xrightarrow{\mathbb{P}}$ 可以增强为 $\xrightarrow{\text{a.s.}}$, 则称 $\hat{\gamma}$ 是强相合的。♣

注 由于参数是常数, 所以依概率收敛与依分布收敛等价。

若把依赖于样本量 n 的估计量 $\hat{\theta}_n$ 看作一个随机变量序列, 相合性就是 $\hat{\theta}_n$ 依概率收敛于 θ , 所以证明估计的相合性可应用依概率收敛的性质及各种大数定律。

例题 3.5 设 x_1, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则由辛钦大数定律及依概率收敛的性质知:

- \bar{x} 是 μ 的相合估计;
- s^{*2} 是 σ^2 的相合估计;
- s^2 也是 σ^2 的相合估计。

由此可见参数的相合估计不止一个。

定理 3.1 (相合性定理)

设 $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ 是 θ 的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是 θ 的相合估计,



证明 由切比雪夫不等式有

$$P(|\hat{\theta}_n - E(\hat{\theta}_n)| \geq \varepsilon/2) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n), \quad \forall \varepsilon > 0$$

另一方面, 由 $\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$ 可知

$$\exists N, \forall n > N, \quad \text{s.t. } |E(\hat{\theta}_n) - \theta| < \varepsilon/2$$

注意到如果 $|\hat{\theta}_n - E(\hat{\theta}_n)| < \varepsilon/2$, 就有

$$|\hat{\theta}_n - \theta| \leq |\hat{\theta}_n - E(\hat{\theta}_n)| + |E(\hat{\theta}_n) - \theta| < \varepsilon$$

故

$$\{|\hat{\theta}_n - E(\hat{\theta}_n)| < \varepsilon/2\} \subset |\hat{\theta}_n - \theta| < \varepsilon$$

等价地

$$\{|\hat{\theta}_n - E(\hat{\theta}_n)| < \varepsilon/2\} \supset \{|\hat{\theta}_n - \theta| < \varepsilon\}$$

由此即有

$$P(|\hat{\theta}_n - \theta| > \varepsilon) \leq P(|\hat{\theta}_n - E(\hat{\theta}_n)| \geq \varepsilon/2) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n) \rightarrow 0$$

定理 3.2 (相合估计的连续映射)

若 $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$ 分别是 $\theta_1, \dots, \theta_k$ 的相合估计, $\eta = g(\theta_1, \dots, \theta_k)$ 是 $\theta_1, \dots, \theta_k$ 的连续函数, 则 $\bar{\eta}_n = g(\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk})$ 是 η 的相合估计。



证明 由函数 g 的连续性, 对 $\forall \varepsilon > 0$, 存在 $\exists \delta > 0$, 当满足 $|\hat{\theta}_j - \theta_j| < \delta, j = 1, \dots, k$ 时, 有

$$|g(\hat{\theta}_1, \dots, \hat{\theta}_k) - g(\theta_1, \dots, \theta_k)| < \varepsilon$$

即

$$\bigcap_{j=1}^k \{|\hat{\theta}_{nj} - \theta_j| < \delta\} \subset \{|\hat{\eta}_n - \eta| < \varepsilon\}$$

又由 $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$ 的相合性得

$$\forall v > 0, \exists N \in \mathbb{N}_+, \forall n > N, \text{ s.t. } P(|\hat{\theta}_{nj} - \theta_j| \geq \delta) < v/k, \quad j = 1, \dots, k$$

从而有

$$\begin{aligned} P(|\hat{\eta}_n - \eta| < \varepsilon) &> P\left(\bigcap_{i=1}^k \{|\hat{\theta}_{nj} - \theta_j| < \delta\}\right) \\ &= 1 - P\left(\bigcup_{j=1}^k \{|\hat{\theta}_{nj} - \theta_j| \geq \delta\}\right) \\ &\geq 1 - \sum_{j=1}^k P(|\hat{\theta}_{nj} - \theta_j| \geq \delta) \\ &> 1 - k \cdot v/k = 1 - v \end{aligned}$$

由 v 的任意性, 定理得证。

3.1.5 漐近正态性

定义 3.8 (漐近正态性)

对于参数 $\tau(\theta)$ 的相合估计 T_n , 若存在趋于 0 的非负常数序列 $\sigma_n(\theta)$, 使得

$$\frac{T_n - \tau(\theta)}{\sigma_n(\theta)} \xrightarrow{d} N(0, 1)$$

则称 T_n 是漐近正态的, 服从漐近正态分布 $N(\tau(\theta), \sigma_n(\theta)^2)$, 记为 $T_n \sim AN(\tau(\theta), \sigma_n(\theta)^2)$, $\sigma_n(\theta)^2$ 为 T_n 的漐近方差或 T_n 的极限分布的方差。



注 $\sigma_n(\theta)$ 表示着估计量 T_n 依概率收敛于 $\tau(\theta)$ 的速度。由中央极限定理可看出, 通常为 $\frac{1}{\sqrt{n}}$ 量级。

例题 3.6 设总体为泊松分布 $P(\lambda)$, 以样本均值为其参数估计, 即

$$\hat{\lambda}_n = \bar{x}_n$$

由中心极限定理, $\frac{\hat{\lambda}_n - \lambda}{\sqrt{\lambda/n}}$ 依分布收敛于 $N(0, 1)$, 因此, $\hat{\lambda}_n$ 是渐近正态的,

3.2 点估计的方法

3.2.1 矩估计

定义 3.9 (总体矩与样本矩)

若 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P_\theta$, 记 k 阶 **总体矩** 为:

$$\mu_k(\theta) = \mathbb{E}_\theta[X_i^k], \quad k \in \mathbb{N}$$

记 k 阶 **样本矩** 为:

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k \in \mathbb{N}$$



命题 3.1 (矩估计的无偏性)

k 阶样本矩是关于总体分布 k 阶矩的无偏估计。



证明

$$E(\hat{\mu}_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k$$

矩方法的步骤:

1. 将低阶矩通过参数表达, 一般阶数与待估参数个数相同 $\mu = f(\theta)$;
2. 找出上一步骤的反函数, 通过矩表达参数 $\theta = f^{-1}(\mu)$;
3. 将样本矩代入, 得到参数的估计式 $\hat{\theta} = f^{-1}(\hat{\mu})$
4. 将参数的矩估计式代入函数 $g(\theta)$, 得到参数的函数 $\eta = g(\theta)$ 的矩估计。

注 对于参数的函数的估计, 矩估计和极大似然估计都是将对参数的估计代入。但极大似然估计的做法是根据其不变性; 而矩估计是源于定义, 不保证与函数的矩估计相同。

例题 3.7 泊松分布的矩估计 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P(\lambda)$, 则其一阶矩 $\mu_1 = \lambda$, 所以 $\lambda = \mu_1$, 其矩估计为:

$$\hat{\lambda} = \hat{\mu}_1 = \bar{X}$$

例题 3.8 设 X_1, \dots, X_n 是独立同分布的连续型随机变量, 具有 p.d.f.

$$f_{\lambda,a}(x) = \lambda e^{-\lambda(x-a)} \mathbb{1}_{[x>a]}, \quad x \in \mathbb{R},$$

其中 $\lambda > 0$ 和 $a \in \mathbb{R}$ 未知 (注: 相应的统计模型是带有位置 (location) 参数和速率 (rate) 参数的指数分布). 易见 $X_i \stackrel{d}{=} a + Y/\lambda$, 其中 $Y \sim \text{Exponential}(1)$. 利用 $\mathbb{E}[Y] = 1$ 和 $\mathbb{E}[Y^2] = 2$, 可以得

到

$$\mu_1(\lambda, a) = a + 1/\lambda, \quad \& \quad \mu_2(\lambda, a) = a^2 + 2a/\lambda + 2/\lambda^2.$$

方程

$$\mu_k(\hat{\lambda}^{\text{MoM}}, \hat{a}^{\text{MoM}}) = \hat{\mu}_k, \quad k = 1, 2$$

的解

$$\hat{\lambda}^{\text{MoM}} = 1 / \sqrt{\hat{\mu}_2 - \hat{\mu}_1^2}, \quad \& \quad \hat{a}^{\text{MoM}} = \hat{\mu}_1 - \sqrt{\hat{\mu}_2 - \hat{\mu}_1^2}$$

即为 (λ, a) 的一种矩估计.

3.2.2 极大然似估计

极大然似估计的基本思想：对于参数空间中的每一个参数，计算在此参数下，观测数据的发生概率，选取最大概率对应的参数。

定义 3.10 (然似函数)

设随机变量 X_1, \dots, X_n 的联合密度函数（或质量函数）为 $f(x_1, \dots, x_n | \theta)$ 。对于某一组观测数据 x_1^*, \dots, x_n^* ，其然似函数 (likelihood function) 为：

$$\mathcal{L}(\theta) = f(x_1^*, \dots, x_n^* | \theta)$$

对数然似函数 (log likelihood function) 为 $l(\theta) = \log \mathcal{L}(\theta)$

注 联合密度质量函数代表概率，但联合密度函数不是，代表概率所占比例；两者都是变量 x 的函数。然似函数是关于参数 θ 的函数，不是概率，对整个参数空间的积分未必等于一。

定义 3.11 (极大然似估计)

可使然似函数取最大值的参数被称为极大然似估计，即

$$\hat{\theta} = \max_{\theta \in \Theta} \mathcal{L}(\theta)$$

注 由于对数函数单调递增，最大化然似函数等价于最大化对数然似函数。

若样本来源变量独立同分布，即 $f(x_1, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$ ，则其然似函数和对数然似函数分布可写为：

$$\mathcal{L}(\theta) = \prod_{i=1}^n f(x_i^* | \theta), \quad l(\theta) = \sum_{i=1}^n \log f(x_i^* | \theta)$$

命题 3.2 (极大然似估计的不变性)

设 $\hat{\theta}$ 是参数 θ 的极大然似估计，那么对于参数 θ 的任意函数 $\gamma = g(\theta)$ ，其极大然似估计 $\hat{\gamma} = g(\hat{\theta})$

证明

3.2.3 贝叶斯估计

贝叶斯估计的基本观点是：任一未知量 θ 都可看作随机变量，可用概率分布 $\pi(\theta)$ 描述，称为先验分布；在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来得到关于未知量 θ 的后验分布 $\pi(\theta|\mathbf{X})$ 。任何关于 θ 的统计推断都基于 θ 的后验分布进行。利用后验分布 $\pi(\theta|\mathbf{X})$ 估计 θ 有三种常用的方法：

- 使用后验分布的密度函数最大值点作为 θ 的点估计的最大后验估计；
- 使用后验分布的中位数作为 θ 的点估计的后验中位数估计；
- 使用后验分布的均值作为 θ 的点估计的后验期望估计。

用得最多的是后验期望估计，它一般也简称为贝叶斯估计，记为的 $\hat{\theta}_B$ 。

获取后验分布的步骤：

1. 根据总体信息与样本信息确定模型 $p(\mathbf{X}|\theta)$ ，根据先验信息确定参数 θ 的先验分布 $\pi(\theta)$
2. 综合总体信息、样本信息和先验信息得到样本 \mathbf{X} 和参数 θ 的联合分布

$$h(\mathbf{X}, \theta) = p(\mathbf{X}|\theta)\pi(\theta)$$

3. 为求后验分布 $\pi(\theta|\mathbf{X}) = \frac{h(\mathbf{X}, \theta)}{m(\mathbf{X})}$ ，先求 X 的边际概率函数：

$$m(\mathbf{X}) = \int_{\theta} h(\mathbf{X}, \theta) d\theta = \int_{\theta} p(\mathbf{X}|\theta)\pi(\theta) d\theta$$

4. 得到后验分布

$$\pi(\theta|\mathbf{X}) = \frac{h(\mathbf{X}, \theta)}{m(\mathbf{X})} = \frac{p(\mathbf{X}|\theta)\pi(\theta)}{\int_{\theta} p(\mathbf{X}|\theta)\pi(\theta) d\theta}$$

定义 3.12 (共轭先验分布)

设 θ 是总体参数， $\pi(\theta)$ 是其先验分布，若对任意的样本观测值得到的后验分布 $\pi(\theta|\mathbf{X})$ 与 $\pi(\theta)$ 属于同一个分布族，则称该分布族是 θ 的共轭先验分布（族）。



例题 3.9 设某事件 A 在一次试验中发生的概率为 θ ，为估计 θ ，对试验进行了 n 次独立观测，其中事件 A 发生了 X 次，显然 $X|\theta \sim b(n, \theta)$ ，即

$$P(X=x|\theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x}, \quad x=0, 1, \dots, n$$

假若我们在试验前对事件 A 没有什么了解，从对其发生的概率也没有任何信息。在这种场合，贝叶斯本人建议采用“同等无知”的原则，使用区间 $(0, 1)$ 上的均匀分布 $U(0, 1)$ 作为 θ 的先验分布。贝叶斯的这个建议被后人称为贝叶斯假设。

解 先写出 X 和 θ 的联合分布

$$h(x, \theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x}, \quad x=0, 1, \dots, n, \quad 0 < \theta < 1$$

然后求 X 的边际分布

$$m(x) = \binom{n}{x} \int_0^1 \theta^x (1-\theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}$$

最后求出 θ 的后验分布

$$\pi(\theta|x) = \frac{h(x, \theta)}{m(x)} = \frac{\Gamma(n+2)}{\Gamma(x+1)\Gamma(n-x+1)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, \quad 0 < \theta < 1$$

即 $\theta|x \sim Be(x+1, n-x+1)$, 故贝塔分布是伯努利试验中成功概率的共轭先验分布。其后验期望估计为

$$\hat{\theta}_B = E(\theta|x) = \frac{x+1}{n+2}$$

例题 3.10 设 x_1, \dots, x_n 是来自 $N(\mu, \sigma_0^2)$ 的一个样本, 其中 σ_0^2 已知, μ 未知。假设 μ 的先验分布亦为正态分布 $N(\theta, \tau^2)$, 其中先验均值 θ 和先验方差 τ^2 均已知, 试求 μ 的贝叶斯估计。

解 样本 \mathbf{X} 的分布和 μ 的先验分布分别为

$$\begin{aligned} p(\mathbf{X}|\mu) &= (2\pi\sigma_0^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \\ \pi(\mu) &= (2\pi\tau^2)^{-1/2} \exp\left\{-\frac{1}{2\tau^2} (\mu - \theta)^2\right\} \end{aligned}$$

由此可以写出 \mathbf{X} 与 μ 的联合分布为

$$h(\mathbf{X}, \mu) = k_1 \cdot \exp\left\{-\frac{1}{2} \left[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{\tau^2} \right] \right\}$$

其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $k_1 = (2\pi)^{-(n+1)/2} \tau^{-1} \sigma_0^{-n}$ 。若记

$$A = \frac{n}{\sigma_0^2} + \frac{1}{\tau^2}, \quad B = \frac{n\bar{x}}{\sigma_0^2} + \frac{\theta}{\tau^2}, \quad C = \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\theta^2}{\tau^2}$$

则有

$$\begin{aligned} h(\mathbf{X}, \mu) &= k_1 \exp\left\{-\frac{1}{2} [A\mu^2 - 2B\mu + C]\right\} \\ &= k_1 \exp\left\{-\frac{(\mu - B/A)^2}{2/A} - \frac{1}{2}(C - B^2/A)\right\} \end{aligned}$$

样本的边际密度函数为

$$m(\mathbf{X}) = \int_{-\infty}^{+\infty} h(\mathbf{X}, \mu) d\mu = k_1 \exp\left\{-\frac{1}{2}(C - B^2/A)\right\} (2\pi/A)^{1/2}$$

应用贝叶斯公式即可得到后验分布

$$\pi(\mu|\mathbf{X}) = \frac{h(\mathbf{X}, \mu)}{m(\mathbf{X})} = (2\pi/A)^{-1/2} \exp\left\{-\frac{1}{2/A} (\mu - B/A)^2\right\}$$

这说明在样本给定后, μ 的后验分布为 $N(B/A, 1/A)$, 即

$$\mu|\mathbf{X} \sim N\left(\frac{n\bar{x}\tau^2 + \theta\sigma_0^2}{n\tau^2 + \sigma_0^2}, \frac{\sigma_0^2\tau^2}{n\tau^2 + \sigma_0^2}\right)$$

故正态分布是正态总体的共轭先验分布。后验均值即为其贝叶斯估计:

$$\hat{\mu} = \frac{n\tau^2}{n\tau^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{n\tau^2 + \sigma_0^2} \theta$$

它是样本均值 \bar{x} 与先验均值 θ 的加权平均。当总体方差 σ_0^2 较小或样本量 n 较大时, 样本均值 \bar{x} 的权重较大; 当先验方差 τ^2 较小时, 先验均值 θ 的权重较大, 这一综合很符合人们的经验。

总体	参数	共轭分布族
$U(\theta - a, \theta + b)$	θ	均匀分布
$B(n, p)$	p	Beta 分布
$Poi(\lambda)$	λ	$Ga(\alpha, \beta) \rightarrow Ga(\alpha + n\bar{x}, \beta + n)$
$N(\mu, \sigma_0^2)$	μ	$N(\theta, \tau^2) \rightarrow N\left(\frac{n\bar{x}\tau^2 + \theta\sigma_0^2}{n\tau^2 + \sigma_0^2}, \frac{\sigma_0^2\tau^2}{n\tau^2 + \sigma_0^2}\right)$
$N(\mu, \sigma^2)$	σ^2	$IGa(\alpha, \lambda) \rightarrow IGa\left(\alpha + \frac{n}{2}, \beta + \frac{n}{2}(x - \mu)^2\right)$

表 3.1: 常见共轭分布族

3.2.4 最小二乘估计

3.3 最小方差无偏估计

由于一致最小均方误差估计（定义3.6）一般都不存在，为方便起见，需对估计加一些合理性前置要求，前述无偏性就是一个最常见的合理性要求。

3.3.1 最小方差无偏估计

定义 3.13 (一致最小方差无偏估计)

设 $\hat{\theta}$ 是 θ 的一个无偏估计，如果对任意一个 θ 的无偏估计 $\tilde{\theta}$ ，在参数空间 Θ 上都有

$$\text{Var}_\theta(\hat{\theta}) \leq \text{Var}_\theta(\tilde{\theta})$$

则称 $\hat{\theta}$ 是 θ 的**一致最小方差无偏估计** (uniformly minimum variance unbiased estimation, UMVUE)。 ♣

定理 3.3 (UMVUE 的充要条件)

设 $\mathbf{X} = (\mathbf{x}_1, \Pi, \mathbf{x}_n)$ 是来自某总体的一个样本， $\hat{\theta} = \hat{\theta}(\mathbf{X})$ 是 θ 的一个无偏估计， $\text{Var}(\hat{\theta}) < +\infty$. 如果对任意一个满足 $E(\varphi(\mathbf{X})) = \mathbf{0}$ 的 $\varphi(\mathbf{X})$ ，都有

$$\text{Cov}_\theta(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta$$

则 $\hat{\theta}$ 是 θ 的 UMVUE。 ♡

证明 充分性： 对 θ 的任意一个无偏估计 $\tilde{\theta}$

$$\text{Var}(\tilde{\theta}) = E(\tilde{\theta} - \theta)^2 = E[(\tilde{\theta} - \hat{\theta}) + (\hat{\theta} - \theta)]^2$$

代入 $\varphi(\mathbf{X}) = \tilde{\theta} - \hat{\theta}$ 得：

$$\text{Var}(\tilde{\theta}) = E(\varphi^2) + \text{Var}(\hat{\theta}) + 2 \text{Cov}(\varphi, \hat{\theta}) \geq \text{Var}(\hat{\theta})$$

必要性: 若存在 $\theta_0 \in \Theta$, 使得 $\text{Cov}_{\theta_0}(\hat{\theta}, \phi(\mathbf{X})) = \mathbf{a} \neq \mathbf{0}$ 。则代入 $\varphi(\mathbf{X}) = \mathbf{b}(\tilde{\theta} - \hat{\theta})$ 得:

$$\text{Var}(\tilde{\theta}) = b^2 E(\varphi^2) + \text{Var}(\hat{\theta}) + 2b \text{Cov}(\varphi, \hat{\theta}) = \text{Var}(\hat{\theta}) + b^2 E(\varphi^2) + 2ab$$

再令 $b = -\frac{a}{E(\varphi^2)} \neq 0$, 则可得 $b^2 E(\varphi^2) + 2ab < 0$, 即 $\text{Var}(\tilde{\theta}) < \text{Var}(\hat{\theta})$, 与假设不符。

例题 3.11 设 x_1, \dots, x_n 是来自指数分布 $\text{Exp}(1/\theta)$ 的样本, 对于充分统计量 $T = x_1 + \dots + x_n$, 由于 $ET = n\theta$, 所以 $\bar{x} = T/n$ 是 θ 的无偏估计。设 $\varphi = \varphi(x_1, \dots, x_n)$ 是 θ 的任一无偏估计, 则

$$E\varphi(\mathbf{X}) = \int_0^{+\infty} \cdots \int_0^{+\infty} \varphi(x_1, \dots, x_n) \cdot \prod_{i=1}^n \left\{ \frac{1}{\theta} \cdot e^{-x_i/\theta} \right\} dx_1 \cdots dx_n = 0$$

即

$$\int_0^{+\infty} \cdots \int_0^{+\infty} \varphi(x_1, \dots, x_n) \cdot \exp \left\{ -\frac{n\bar{x}}{\theta} \right\} dx_1 \cdots dx_n = 0$$

两端对 θ 求导, 得

$$\int_0^{+\infty} \cdots \int_0^{+\infty} \varphi(x_1, \dots, x_n) \frac{n\bar{x}}{\theta^2} \cdot \exp \left\{ -\frac{n\bar{x}}{\theta} \right\} dx_1 \cdots dx_n = 0$$

这说明 $E(\bar{x} \cdot \varphi) = 0$, 从而

$$\text{Cov}(\bar{x}, \varphi) = E(\bar{x} \cdot \varphi) - E(\bar{x}) \cdot E(\varphi) = 0$$

即 \bar{x} 是 θ 的 UMVUE.

3.3.2 充分性原则

引理 3.1 (Rao–Blackwell 定理)

设 X 和 Y 是两个随机变量, $EX = \mu, \text{Var}(X) > 0$ 。用条件期望构造一个新的随机变量 $\varphi(Y) = E(X|Y)$, 则有

$$E\varphi(Y) = \mu, \text{Var}(\varphi(Y)) \leq \text{Var}(X)$$

其中等号成立的充分必要条件是 X 和 $\varphi(Y)$ 几乎处处相等。



证明 由重期望公式易得

$$E\varphi(Y) = E[E(X|Y)] = EX = \mu$$

将 $\text{Var}(X)$ 写成如下的形式:

$$\begin{aligned} \text{Var}(X) &= E[(X - \varphi(Y)) + (\varphi(Y) - \mu)]^2 \\ &= E(X - \varphi(Y))^2 + \text{Var}(\varphi(Y) - \mu) + 2E[(X - \varphi(Y))(\varphi(Y) - \mu)] \end{aligned}$$

由重期望公式

$$\begin{aligned} E[(X - \varphi(Y))(\varphi(Y) - \mu)] &= E\{E[(X - \varphi(Y))(\varphi(Y) - \mu)|Y]\} \\ &= E\{[\varphi(Y) - \mu][E(X|Y) - \varphi(Y)]\} = 0 \end{aligned}$$

由此即有

$$\text{Var}(X) = E(X - \varphi(Y))^2 + \text{Var}(\varphi(Y)) \leq \text{Var}(\varphi(Y))$$

等号成立的充要条件为

$$E[X - \varphi(Y)]^2 = 0$$

即 X 和 $\varphi(Y)$ 几乎处处相等。

定理 3.4 (充分性原则)

设, $T = T(x_1, \dots, x_n)$ 是 θ 的充分统计量, 则对 θ 的任一无偏估计 $\hat{\theta}$, 令 $\tilde{\theta} = E(\hat{\theta}|T)$, 则 $\tilde{\theta}$ 也是 θ 的无偏估计, 且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta})$$



证明 由于 T 是充分统计量, 故而 $\tilde{\theta} = E(\hat{\theta}|T)$ 与 θ 无关, 因此它也是一个估计 (统计量)。再将引理3.1取 $X = \hat{\theta}, Y = T$ 即可。

例题 3.12 设 $x_1, \dots, x_n \stackrel{\text{i.i.d.}}{\sim} b(1, p)$, 则 \bar{x} (或 $T = n\bar{x}$) 是 p 的充分统计量. 为估计 $\theta = p^2$, 可令

$$\hat{\theta}_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1; \\ 0, & \text{其他.} \end{cases}$$

由于

$$E(\hat{\theta}_1) = P(x_1 = 1, x_2 = 1) = p \cdot p = \theta$$

所以, $\hat{\theta}_1$ 是 θ 的无偏估计, 这个估计并不好, 它只使用了两个观测值, 下面我们用 Rao–Blackwell 定理对之加以改进: 求 $\hat{\theta}_1$ 关于充分统计量 $T = \sum_{i=1}^n x_i$ 的条件期望

$$\begin{aligned} \hat{\theta} &= E(\hat{\theta}_1|T = t) \\ &= P(\hat{\theta}_1 = 1|T = t) \\ &= \frac{P(X_1 = 1, X_2 = 1, T = t)}{P(T = t)} \\ &= \frac{P(X_1 = 1, X_2 = 1, \sum_{i=3}^n X_i = t - 2)}{P(T = t)} \\ &= \frac{p \cdot p \cdot \binom{n-2}{t-2} p^{t-2} (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \binom{n-2}{t-2} / \binom{n}{t} = \frac{t(t-1)}{n(n-1)}, \end{aligned}$$

3.3.3 费希尔信息量

定义 3.14

若总体分布 $p(x; \theta), \theta \in \Theta$ 满足

1. 参数空间 Θ 是直线上的一个开区间;
2. 支撑 $S = \{x : p(x; \theta) > 0\}$ 与 Θ 无关;
3. 导数 $\frac{\partial}{\partial \theta} p(x; \theta)$ 对一切 $\theta \in \Theta$ 都存在;

4. 对 $p(x; \theta)$, 积分与微分运算可交换次序, 即

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} p(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial}{\partial \theta} p(x; \theta) dx$$

5. 期望 $E\left[\frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2$ 存在,

则称

$$I(\theta) = E\left[\frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2$$

为总体分布的费希尔信息量 (Fisher)。



注 “ $I(\theta)$ 越大” 代表总体分布中包含未知参数 θ 的信息越多。

命题 3.3

若总体 $p(x; \theta)$ 的费希尔信息量存在, 且存在二阶导数 $\frac{\partial^2}{\partial \theta^2} p(x; \theta) \forall \theta \in \Theta$, 则

$$I(\theta) = -E\left[\frac{\partial^2}{\partial \theta^2} \ln p(x; \theta)\right]$$



证明 由于

$$\int p(x; \theta) dx = 1$$

两边同时对 θ 求偏导得:

$$\frac{\partial}{\partial \theta} \int p(x; \theta) dx = \int \frac{\partial}{\partial \theta} p(x; \theta) dx = \int \frac{\partial}{\partial \theta} \ln p(x; \theta) p(x; \theta) dx = 0$$

再同时对 θ 求偏导得:

$$\int \left[\frac{\partial^2}{\partial \theta^2} \ln p(x; \theta) \right] p(x; \theta) dx + \int \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2 p(x; \theta) dx = 0$$

即

$$E\left[\frac{\partial^2}{\partial \theta^2} \ln p(x; \theta)\right] + I(\theta) = 0$$

命题 3.4

对于总体分布 $p(x; \theta)$, 若其参数 θ 的费希尔信息量存在且为 $I(\theta)$, 则对于参数的函数 $\tau(\theta)$ 的费希尔信息量为

$$I(\tau(\theta)) = E\left[\frac{\partial}{\partial \tau(\theta)} \ln p(x; \theta)\right]^2 = \frac{I(\theta)}{[\tau'(\theta)]^2}$$



证明

$$\begin{aligned} I(\tau(\theta)) &= E\left[\frac{\partial}{\partial \tau(\theta)} \ln p(x; \theta)\right]^2 = E\left[\frac{\partial \theta}{\partial \tau(\theta)} \frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2 \\ &= \left[\frac{\partial \theta}{\partial \tau(\theta)}\right]^2 E\left[\frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2 = \frac{I(\theta)}{[\tau'(\theta)]^2} \end{aligned}$$

3.3.4 Cramer-Rao 不等式

定理 3.5 (Cramer-Rao 不等式)

设总体分布 $p(x; \theta)$ 存在费希尔统计量。若对 $g(\theta)$ 的任一个无偏估计 T ,

$$g(\theta) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, \dots, x_n) \prod_{i=1}^n p(x_i; \theta) dx_1 \cdots dx_n, \quad \forall \theta \in \Theta$$

的微商 $g'(\theta) = \frac{dg(\theta)}{d\theta}$ 存在, 并且可在积分号下进行, 即

$$\begin{aligned} g'(\theta) &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left(\prod_{i=1}^n p(x_i; \theta) \right) dx_1 \cdots dx_n \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, \dots, x_n) \left[\frac{\partial}{\partial \theta} \ln \prod_{i=1}^n p(x_i; \theta) \right] \prod_{i=1}^n p(x_i; \theta) dx_1 \cdots dx_n \end{aligned}$$

对离散总体, 则将上述积分改为求和符号后, 等式仍然成立. 则有

$$\text{Var}(T) \geq \frac{1}{nI(g(\theta))}$$

特别地, 对 θ 的无偏估计 $\hat{\theta}$, 有 $\text{Var}(\hat{\theta}) \geq (nI(\theta))^{-1}$.



证明 以连续总体为例: 由于

$$\int p(x_i; \theta) dx_i = 1$$

两边同时对 θ 求偏导, 由于积分与微分可交换次序, 于是有:

$$\begin{aligned} \frac{\partial}{\partial \theta} \int p(x_i; \theta) dx_i &= \int \frac{\partial}{\partial \theta} p(x_i; \theta) dx_i = \int \frac{\partial}{\partial \theta} \ln p(x_i; \theta) p(x_i; \theta) dx_i \\ &= E \left[\frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right] = 0 \end{aligned}$$

记

$$Z = \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n p(x_i; \theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln p(x_i; \theta)$$

则

$$E(Z) = \sum_{i=1}^n E \left[\frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right] = 0$$

从而

$$\begin{aligned} \text{Var}(Z) &= \sum_{i=1}^n \text{Var} \left(\frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right) \\ &= \sum_{i=1}^n E \left[\left(\frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right)^2 \right] = nI(\theta) \end{aligned}$$

又由

$$g'(\theta) = E(T \cdot Z) = E((T - g(\theta)) \cdot Z)$$

据施瓦茨不等式，有

$$\left[g'(\theta) \right]^2 \leq E[(T - g(\theta))^2] \cdot E(Z^2) = \text{Var}(T) \text{Var}(Z)$$

关于离散总体可类似证明。

定义 3.15 (CR 下界)

称 $\frac{1}{nI(g(\theta))}$ 为 $g(\theta)$ 的无偏估计的方差的 **C-R 下界**，简称 $g(\theta)$ 的 CR 下界。若估计式的方差达到 C-R 下界，则称其为参数的**有效估计**，即 UMVUE。

错题记录

1. (茆 6.1.14) 设 x_1, \dots, x_n 是来自二点分布 $b(1, p)$ 的一个样本，证明 $\frac{1}{p}$ 的无偏估计不存在。
2. (茆 6.2.3(2)) 设总体分布列为 $P(X = k) = (k-1)\theta^2(1-\theta)^{k-2}$, $k = 2, 3, \dots, 0 < \theta < 1$ 如下, x_1, x_2, \dots, x_n ，试求未知参数的矩估计。
3. (茆 6.4.3)
4. (茆 6.4.4)
5. (茆 6.4.5)
6. (茆 6.4.6)
7. (茆 6.4.9)
8. (茆 6.4.11)
9. (茆 6.4.12)
10. (茆 6.4.13)
11. (茆 6.4.14)
12. (茆 6.4.16-20)
13. (茆 6.5.12-16)

第 4 章 区间估计

4.1 区间估计的概念

4.2 枢轴变量法

4.2.1 正态总体参数

4.2.2 非正态总体参数

4.3 Fisher 的信仰推断法

4.4 容忍区间于容忍限

~~~~~ 错题记录 ~~~~

1. (茆 6.6.11)
2. (茆 6.6.13)
3. (茆 6.6.15-18)
4. (茆 6.6.20-24)

# 第 5 章 假设检验

## 5.1 假设检验的概念

### 5.1.1 基本思想

基本思想：将样本空间  $\Omega$  拆分为两个不相交的集合  $\Omega_0, \Omega_A$  即

$$\Omega_0 \cap \Omega_A = \emptyset, \Omega_0 \cup \Omega_A = \Omega$$

接下来通过数据选择应该接受两个假设

$$H_0 : \Theta \in \Omega_0, H_A : \Theta \in \Omega_A$$

中的哪一个。

问：是否能用点估计代替假设检验？即若估计结果  $\hat{\Theta} \in \Omega_0$ ，则接受假设  $H_0$ ；或反之。

假设某一总体遵循二项分布  $B(n, p)$ ，做出如下假设：

$$H_0 : p = 0.5, H_A : p \neq 0.5$$

若  $n = 10^5$ ，估计值  $\hat{p} = 0.50001$ 。按估计结果应认为  $H_A$  成立，然而一般按情理而言，似乎  $H_0$  更恰当。这体现出点估计与假设检验的不同：点估计的结果是客观的；而假设检验的结果包含一定的主观性。

若假设可用一个参数的集合表示，该假设检验问题称为参数假设检验问题，否则称为非参数假设检验问题。上例就是一个参数假设检验问题，而对假设“总体为正态分布”作出检验的问题则是一个非参数假设检验问题。

#### 定义 5.1 (原假设与对立假设)

设有来自某一个参数分布族  $\{F(x, \theta) | \theta \in \Theta\}$  的样本  $x_1, \dots, x_n$ ，其中  $\Omega$  为参数空间。设  $\Theta_0 \in \Theta, \Theta_0 \neq \emptyset$ ，则命题  $H_0 : \Theta \in \Omega_0$  称为或原假设或零假设 (null hypothesis)；并称命题  $H_A : \Theta \in \Omega_A, \Theta_A = \Theta - \Theta_0$  为  $H_0$  的对立假设或备择假设 (alternative hypothesis)。

#### 定义 5.2

如果假设（原假设或对立假设）只含一个点，则称之为简单假设 (simple hypothesis)，否则称为复合假设 (composite hypothesis)。

当  $H_0$  为简单假设时，其形式可写成  $H_0 : \theta = \theta_0$ ，此时的备择假设通常有如下三种可能：

$$H_A' : \theta \neq \theta_0, H_A'' : \theta < \theta_0, H_A''' : \theta > \theta_0,$$

称  $H_0$ v.s. $H_A'$  为双侧假设或双边假设； $H_0$ v.s. $H_A''$  以及  $H_0$ v.s. $H_A'''$  为单侧假设或单边假设。

### 5.1.2 Neyman-Pearson 范式

#### 定义 5.3

对于样本空间  $S$ , 若有一种规则将其划分为两个互不相交的区域  $W, \bar{W}$ , 并且当样本  $\mathbf{x} \in W$  时, 选择假设  $H_A$ , 否则接受假设  $H_0$ , 则将这种划分称为 **检定** (test), 将  $W$  与  $\bar{W}$  分别称为 **拒绝域** (rejection region, RR) 与 **接受域** (acceptance region, AR)。



根据检定结果与实际参数的不同, 参见表5.1有 4 种可能的情况:

表 5.1: 检验的 4 种情况

|      |                      | 总体情况     |          |
|------|----------------------|----------|----------|
|      |                      | $H_0$ 为真 | $H_1$ 为真 |
| 数据情况 | $\mathbf{x} \in W$   | 一类错误     | 正确       |
|      | $\mathbf{x} \in W^c$ | 正确       | 二类错误     |

## 5.2 正态总体参数假设检验

### 5.3 然似比检验

### 5.4 一致最优检验

### 5.5 无偏检验

### 5.6 假设检验与区间估计

#### 错题记录

1. (茆 7.1.1)

2.

# 第 6 章 线性模型

6.1 回归分析

6.2 最小二乘法

6.3 方差分析