



# 数理统计笔记

作者：肖程哲

时间：November 17, 2022



苟日新，日日新，又日新

# 目录

<b>第 1 章 导论: 从数据中学习</b>	<b>1</b>	3.3.3 费希尔信息量 . . . . .	16
1.1 统计模型 . . . . .	1	3.3.4 Cramer-Rao 不等式 . .	18
1.2 统计量 . . . . .	2	<b>第 3 章 练习</b> . . . . .	19
<b>第 1 章 练习</b> . . . . .	<b>2</b>		
<b>第 2 章 抽样分布</b>	<b>3</b>	<b>第 4 章 区间估计</b>	<b>9</b>
2.1 统计量的极限分布 . . . . .	3	4.1 区间估计的概念 . . . . .	9
2.2 指数族 . . . . .	3	4.2 枢轴变量法 . . . . .	9
2.3 充分统计量 . . . . .	3	4.2.1 正态总体参数 . . . . .	9
2.4 完全统计量 . . . . .	4	4.2.2 非正态总体参数 . . . . .	9
		4.3 Fisher 的信仰推断法 . . . . .	9
		4.4 容忍区间与容忍限 . . . . .	9
<b>第 3 章 点估计</b>	<b>5</b>	<b>第 5 章 假设检验</b>	<b>10</b>
3.1 点估计的评价方法 . . . . .	5	5.1 假设检验的概念 . . . . .	10
3.1.1 无偏性 . . . . .	5	5.1.1 基本思想 . . . . .	10
3.1.2 有效性 . . . . .	6	5.1.2 Neyman-Pearson 范式 .	10
3.1.3 均方误差 . . . . .	7	5.2 正态总体参数假设检验 . . . .	11
3.1.4 相合性 . . . . .	8	5.3 然似比检验 . . . . .	11
3.1.5 渐近正态性 . . . . .	9	5.4 一致最优检验 . . . . .	11
3.2 点估计的方法 . . . . .	10	5.5 无偏检验 . . . . .	11
3.2.1 矩估计 . . . . .	10	5.6 假设检验与区间估计 . . . . .	11
3.2.2 极大然似估计 . . . . .	11	<b>第 5 章 练习</b> . . . . .	11
3.2.3 贝叶斯估计 . . . . .	12		
3.2.4 最小二乘估计 . . . . .	14		
3.3 最小方差无偏估计 . . . . .	14	<b>第 6 章 线性模型</b>	<b>12</b>
3.3.1 最小方差无偏估计 . .	14	6.1 回归分析 . . . . .	12
3.3.2 充分性原则 . . . . .	15	6.2 最小二乘法 . . . . .	12
		6.3 方差分析 . . . . .	12

# 第3章 点估计

## 考试重点

- 矩估计和极大似然估计
- 点估计的其他评价方法
- UMVUE
- (弱) 相合和强相合
- Fisher 信息量和有效估计
- 贝叶斯估计

### 定义 3.1 (点估计)

用于估计参数  $\gamma = g(\theta)$  的统计量  $T(\mathbf{X})$  称为 **估计量** (estimator), 记为  $\hat{\gamma} = T(\mathbf{X})$ . 估计式是随机变量, 若给定统计模型, 则其分布由参数  $\theta$  决定, 将观测数值代入估计式后得到的值称为 **估计值**.



将数据代入估计式得到的估计值并不是真实的参数值, 若使用新的样本, 很可能会得到不同的估计值。

## 3.1 点估计的评价方法

### 3.1.1 无偏性

#### 定义 3.2 (无偏估计)

估计式的**偏差** (standard error) 定义为其抽样分布的均值与实际参数的偏差, 即:

$$E(\hat{\theta}) - \theta$$

若其为零, 则称此估计为参数  $\theta$  的**无偏估计**



#### 例题 3.1 方差的无偏估计

$$\begin{aligned}s^2 &= \frac{1}{n-1} \sum_{i=0}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left[ \sum_{i=0}^n X_i^2 - n\bar{X}^2 \right] \\&= \frac{1}{n-1} \left[ \sum_{i=0}^n X_i^2 - \frac{1}{n} (\sum_{i=0}^n X_i)^2 \right] = \frac{1}{n-1} \left[ \sum_{i=0}^n X_i^2 - \frac{1}{n} \left( \sum_{i=0}^n X_i^2 + \sum_{i \neq j} X_i X_j \right) \right] \\&= \frac{1}{n} \sum_{i=0}^n X_i^2 - \frac{1}{n(n-1)} \sum_{i \neq j} X_i X_j \\E(s^2) &= \frac{1}{n} \sum_{i=0}^n E(X_i^2) - \frac{1}{n(n-1)} \sum_{i \neq j} E(X_i X_j) = \mu_2 - m_1^2 = \sigma^2\end{aligned}$$

**定义 3.3 (渐进无偏估计)**

若样本量趋于无穷时，估计式的偏差为零，即：

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$$

则称此估计为参数  $\theta$  的渐近无偏估计



**例题 3.2 样本方差的渐进无偏性** 对于样本方差  $s_n^2 = \frac{1}{n} \sum_{i=0}^n (X_i - \bar{X})^2$ , 其期望为  $E(s_n^2) = \frac{n-1}{n} \sigma^2$ 。当样本量趋于无穷时，有  $E(s^2) \rightarrow \sigma^2$ 。故  $s^2$  为  $\sigma^2$  的渐近无偏估计。

无偏性不具有不变性，即若  $\hat{\theta}$  是  $\theta$  的无偏估计，一般而言，其函数  $g(\hat{\theta})$  不是  $g(\theta)$  的无偏估计，除非  $g(\theta)$  是  $\theta$  的线性函数。譬如， $s^2$  是  $\sigma^2$  的无偏估计，但  $s$  不是  $\sigma$  的无偏估计。

**例题 3.3** 设总体为  $N(\mu, \sigma^2)$ ,  $x_1, \dots, x_n$  是样本，考察  $s$  是否是  $\sigma$  的无偏估计。 $Y = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$ , 其密度函数为

$$p(y) = \frac{1}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} y^{\frac{n-1}{2}-1} e^{-\frac{y}{2}}, \quad y > 0$$

从而

$$\begin{aligned} E(Y^{1/2}) &= \int_0^{+\infty} y^{1/2} p(y) dy = \frac{1}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} \int_0^{\infty} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} dy \\ &= \frac{2^{\frac{n}{2}} \Gamma(\frac{n}{2})}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} = \sqrt{2} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \end{aligned}$$

由此，我们有

$$E(s) = \frac{\sigma}{\sqrt{n-1}} E(Y^{1/2}) = \sqrt{\frac{2}{n-1}} \cdot \frac{\Gamma(n/2)}{\Gamma((n-1)/2)} \cdot \sigma$$

这说明  $s$  不是  $\sigma$  的无偏估计。

当参数存在无偏估计时，我们称该参数是可估的，否则称它是不可估的。

### 3.1.2 有效性

参数的无偏估计可以有很多，如何在无偏估计中进行选择？直观的想法是希望该估计围绕参数真值的波动越小越好，波动大小可以用方差来衡量，因此人们常用无偏估计的方差的大小作为度量无偏估计优劣的标准，这就是有效性。

**定义 3.4 (有效性)**

设  $\hat{\theta}_1, \hat{\theta}_2$  是  $\theta$  的两个无偏估计，如果对任意的  $\theta \in \Theta$  有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

且至少有一个  $\theta \in \Theta$  使得上述不等号严格成立，则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效。



### 3.1.3 均方误差

无偏性是估计的一个优良性质，对无偏估计我们还可以通过其方差进行有效性比较。然而不能由此认为：有偏估计一定是不好的估计。

在有些场合，有偏估计比无偏估计更优，这就涉及如何对有偏估计进行评价。一般而言，在样本量一定时，评价一个点估计的好坏使用的度量指标总是点估计值与参数真值  $\theta$  的距离的函数，最常用的函数是距离的平方。由于具有随机性，可以对该函数求期望，

#### 定义 3.5

估计式与参数的平方的期望称为**均方误差**

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2$$



注意到

$$\begin{aligned}\text{MSE}(\hat{\theta}) &= [E(\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)^2] \\ &= E(\hat{\theta} - E\hat{\theta})^2 + (E\hat{\theta} - \theta)^2 + 2E[(\hat{\theta} - E\hat{\theta})(E\hat{\theta} - \theta)] \\ &= \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2\end{aligned}$$

因此，均方误差由点估计的方差与偏差的平方两部分组成。如果  $\hat{\theta}$  是  $\theta$  的无偏估计，则  $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$ ，此时用均方误差评价点估计与用方差是一样的；当  $\hat{\theta}$  不是  $\theta$  的无偏估计时，就要看其均方误差  $\text{MSE}(\hat{\theta})$ ，即不仅要看其方差大小，还要看其偏差大小。

#### 定义 3.6 (一致最小均方误差估计)

在一个估计类中，若其中的一个估计式  $\hat{\theta}$  对估计类中任意一个估计式  $\tilde{\theta}$ ，在参数空间  $\Theta$  上满足

$$\text{MSE}_{\theta}(\hat{\theta}) \leq \text{MSE}_{\theta}(\tilde{\theta}), \quad \forall \theta \in \Theta$$

则称此估计式为该估计类中  $\theta$  的**一致最小均方误差估计**。



**例题 3.4** 对均匀总体  $U(0, \theta)$ ，考虑  $\theta$  的形如  $\hat{\theta}_\alpha = \alpha \cdot x_{(n)}$  的估计，其均方误差为

$$\begin{aligned}\text{MSE}(\hat{\theta}_\alpha) &= \text{Var}(\alpha \cdot x_{(n)}) + (\alpha E x_{(n)} - \theta)^2 \\ &= \alpha^2 \text{Var}(x_{(n)}) + \left(\alpha \frac{n}{n+1} \theta - \theta\right)^2 \\ &= \alpha^2 \frac{n}{(n+1)^2(n+2)} + \left(\frac{n \cdot \alpha}{n+1} - 1\right)^2 \theta^2.\end{aligned}$$

用求导的方法不难求出当  $\alpha_0 = (n+2)/(n+1)$  时上述均方误差达到最小，此时  $\text{MSE}\left(\frac{n+2}{n+1} x_{(n)}\right) = \frac{\theta^2}{(n+1)^2}$ 。 $\hat{\theta}_0 = \frac{n+2}{n+1} x_{(n)}$  虽是  $\theta$  的有偏估计，但对于无偏估计  $\hat{\theta} = \frac{n+1}{n} x_{(n)}$  而言，其均方误差  $\text{MSE}(\hat{\theta}_0) = \frac{\theta^2}{(n+1)^2} < \frac{\theta^2}{n(n+2)} = \text{MSE}(\hat{\theta})$ 。所以在均方误差的标准下，有偏估计  $\hat{\theta}_0$  优于无偏估计  $\hat{\theta}$ 。并且  $\hat{\theta}_0$  为形如  $\alpha \cdot x_{(n)}$  的估计类中  $\theta$  的一致最小均方误差估计。

若不对估计加以限制（即考虑所有可能的估计），则一致最小均方误差估计是不存在的，从而没有意义。事实上，若  $\hat{\theta}$  是  $\theta$  的所有估计中的一致最小均方误差估计，取定任一个  $\theta_0 \in$

Theta, 令  $\tilde{\theta} = \theta_0$ , 则  $MSE_{\theta_0}(\tilde{\theta}) = 0$ , 于是要求  $\hat{\theta}_0$  也有  $MSE_{\theta_0}(\hat{\theta}) = 0$ , 由  $\theta_0$  的任意性, 这意味着  $MSE_{\theta}$  处处为 0, 这显然是做不到的。

### 3.1.4 相合性

#### 定义 3.7 (相合)

若当样本容量  $n \rightarrow \infty$  时, 有

$$\hat{\gamma} \xrightarrow{\mathbb{P}} \gamma, \quad \forall \theta \in \Theta.$$

则称  $\hat{\gamma}$  是相合的/一致的 (consistent), 如果上式中  $\xrightarrow{\mathbb{P}}$  可以增强为  $\xrightarrow{\text{a.s.}}$ , 则称  $\hat{\gamma}$  是强相合的。♣

**注** 由于参数是常数, 所以依概率收敛与依分布收敛等价。

若把依赖于样本量  $n$  的估计量  $\hat{\theta}_n$  看作一个随机变量序列, 相合性就是  $\hat{\theta}_n$  依概率收敛于  $\theta$ , 所以证明估计的相合性可应用依概率收敛的性质及各种大数定律。

**例题 3.5** 设  $x_1, \dots, x_n$  是来自正态总体  $N(\mu, \sigma^2)$  的样本, 则由辛钦大数定律及依概率收敛的性质知:

- $\bar{x}$  是  $\mu$  的相合估计;
- $s^{*2}$  是  $\sigma^2$  的相合估计;
- $s^2$  也是  $\sigma^2$  的相合估计。

由此可见参数的相合估计不止一个。

#### 定理 3.1 (相合性定理)

设  $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$  是  $\theta$  的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

则  $\hat{\theta}_n$  是  $\theta$  的相合估计,



**证明** 由切比雪夫不等式有

$$P(|\hat{\theta}_n - E(\hat{\theta}_n)| \geq \varepsilon/2) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n), \quad \forall \varepsilon > 0$$

另一方面, 由  $\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$  可知

$$\exists N, \forall n > N, \quad \text{s.t. } |E(\hat{\theta}_n) - \theta| < \varepsilon/2$$

注意到如果  $|\hat{\theta}_n - E(\hat{\theta}_n)| < \varepsilon/2$ , 就有

$$|\hat{\theta}_n - \theta| \leq |\hat{\theta}_n - E(\hat{\theta}_n)| + |E(\hat{\theta}_n) - \theta| < \varepsilon$$

故

$$\{|\hat{\theta}_n - E(\hat{\theta}_n)| < \varepsilon/2\} \subset |\hat{\theta}_n - \theta| < \varepsilon$$

等价地

$$\{|\hat{\theta}_n - E(\hat{\theta}_n)| < \varepsilon/2\} \supset \{|\hat{\theta}_n - \theta| < \varepsilon\}$$

由此即有

$$P(|\hat{\theta}_n - \theta| > \varepsilon) \leq P(|\hat{\theta}_n - E(\hat{\theta}_n)| \geq \varepsilon/2) \leq \frac{4}{\varepsilon^2} \text{Var}(\hat{\theta}_n) \rightarrow 0$$

### 定理 3.2 (相合估计的连续映射)

若  $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$  分别是  $\theta_1, \dots, \theta_k$  的相合估计,  $\eta = g(\theta_1, \dots, \theta_k)$  是  $\theta_1, \dots, \theta_k$  的连续函数, 则  $\bar{\eta}_n = g(\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk})$  是  $\eta$  的相合估计。



**证明** 由函数  $g$  的连续性, 对  $\forall \varepsilon > 0$ , 存在  $\exists \delta > 0$ , 当满足  $|\hat{\theta}_j - \theta_j| < \delta, j = 1, \dots, k$  时, 有

$$|g(\hat{\theta}_1, \dots, \hat{\theta}_k) - g(\theta_1, \dots, \theta_k)| < \varepsilon$$

即

$$\bigcap_{j=1}^k \{|\hat{\theta}_{nj} - \theta_j| < \delta\} \subset \{|\hat{\eta}_n - \eta| < \varepsilon\}$$

又由  $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$  的相合性得

$$\forall v > 0, \exists N \in \mathbb{N}_+, \forall n > N, \text{ s.t. } P(|\hat{\theta}_{nj} - \theta_j| \geq \delta) < v/k, \quad j = 1, \dots, k$$

从而有

$$\begin{aligned} P(|\hat{\eta}_n - \eta| < \varepsilon) &> P\left(\bigcap_{i=1}^k \{|\hat{\theta}_{nj} - \theta_j| < \delta\}\right) \\ &= 1 - P\left(\bigcup_{j=1}^k \{|\hat{\theta}_{nj} - \theta_j| \geq \delta\}\right) \\ &\geq 1 - \sum_{j=1}^k P(|\hat{\theta}_{nj} - \theta_j| \geq \delta) \\ &> 1 - k \cdot v/k = 1 - v \end{aligned}$$

由  $v$  的任意性, 定理得证。

## 3.1.5 漐近正态性

### 定义 3.8 (漐近正态性)

对于参数  $\tau(\theta)$  的相合估计  $T_n$ , 若存在趋于 0 的非负常数序列  $\sigma_n(\theta)$ , 使得

$$\frac{T_n - \tau(\theta)}{\sigma_n(\theta)} \xrightarrow{d} N(0, 1)$$

则称  $T_n$  是漐近正态的, 服从漐近正态分布  $N(\tau(\theta), \sigma_n(\theta)^2)$ , 记为  $T_n \sim AN(\tau(\theta), \sigma_n(\theta)^2)$ ,  $\sigma_n(\theta)^2$  为  $T_n$  的漐近方差或  $T_n$  的极限分布的方差。



**注**  $\sigma_n(\theta)$  表示着估计量  $T_n$  依概率收敛于  $\tau(\theta)$  的速度。由中央极限定理可看出, 通常为  $\frac{1}{\sqrt{n}}$  量级。

**例题 3.6** 设总体为泊松分布  $P(\lambda)$ , 以样本均值为其参数估计, 即

$$\hat{\lambda}_n = \bar{x}_n$$

由中心极限定理,  $\frac{\hat{\lambda}_n - \lambda}{\sqrt{\lambda/n}}$  依分布收敛于  $N(0, 1)$ , 因此,  $\hat{\lambda}_n$  是渐近正态的,

## 3.2 点估计的方法

### 3.2.1 矩估计

#### 定义 3.9 (总体矩与样本矩)

若  $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P_\theta$ , 记  $k$  阶 **总体矩** 为:

$$\mu_k(\theta) = \mathbb{E}_\theta[X_i^k], \quad k \in \mathbb{N}$$

记  $k$  阶 **样本矩** 为:

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k \in \mathbb{N}$$



#### 命题 3.1 (矩估计的无偏性)

$k$  阶样本矩是关于总体分布  $k$  阶矩的无偏估计。



#### 证明

$$E(\hat{\mu}_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k$$

矩方法的步骤:

1. 将低阶矩通过参数表达, 一般阶数与待估参数个数相同  $\mu = f(\theta)$ ;
2. 找出上一步骤的反函数, 通过矩表达参数  $\theta = f^{-1}(\mu)$ ;
3. 将样本矩代入, 得到参数的估计式  $\hat{\theta} = f^{-1}(\hat{\mu})$
4. 将参数的矩估计式代入函数  $g(\theta)$ , 得到参数的函数  $\eta = g(\theta)$  的矩估计。

**注** 对于参数的函数的估计, 矩估计和极大似然估计都是将对参数的估计代入。但极大似然估计的做法是根据其不变性; 而矩估计是源于定义, 不保证与函数的矩估计相同。

**例题 3.7 泊松分布的矩估计** 设  $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P(\lambda)$ , 则其一阶矩  $\mu_1 = \lambda$ , 所以  $\lambda = \mu_1$ , 其矩估计为:

$$\hat{\lambda} = \hat{\mu}_1 = \bar{X}$$

**例题 3.8** 设  $X_1, \dots, X_n$  是独立同分布的连续型随机变量, 具有 p.d.f.

$$f_{\lambda,a}(x) = \lambda e^{-\lambda(x-a)} \mathbb{1}_{[x>a]}, \quad x \in \mathbb{R},$$

其中  $\lambda > 0$  和  $a \in \mathbb{R}$  未知 (注: 相应的统计模型是带有位置 (location) 参数和速率 (rate) 参数的指数分布). 易见  $X_i \stackrel{d}{=} a + Y/\lambda$ , 其中  $Y \sim \text{Exponential}(1)$ . 利用  $\mathbb{E}[Y] = 1$  和  $\mathbb{E}[Y^2] = 2$ , 可以得

到

$$\mu_1(\lambda, a) = a + 1/\lambda, \quad \& \quad \mu_2(\lambda, a) = a^2 + 2a/\lambda + 2/\lambda^2.$$

方程

$$\mu_k(\hat{\lambda}^{\text{MoM}}, \hat{a}^{\text{MoM}}) = \hat{\mu}_k, \quad k = 1, 2$$

的解

$$\hat{\lambda}^{\text{MoM}} = 1 / \sqrt{\hat{\mu}_2 - \hat{\mu}_1^2}, \quad \& \quad \hat{a}^{\text{MoM}} = \hat{\mu}_1 - \sqrt{\hat{\mu}_2 - \hat{\mu}_1^2}$$

即为  $(\lambda, a)$  的一种矩估计.

### 3.2.2 极大然似估计

极大然似估计的基本思想：对于参数空间中的每一个参数，计算在此参数下，观测数据的发生概率，选取最大概率对应的参数。

#### 定义 3.10 (然似函数)

设随机变量  $X_1, \dots, X_n$  的联合密度函数（或质量函数）为  $f(x_1, \dots, x_n | \theta)$ 。对于某一组观测数据  $x_1^*, \dots, x_n^*$ ，其然似函数 (likelihood function) 为：

$$\mathcal{L}(\theta) = f(x_1^*, \dots, x_n^* | \theta)$$

对数然似函数 (log likelihood function) 为  $l(\theta) = \log \mathcal{L}(\theta)$

**注** 联合密度质量函数代表概率，但联合密度函数不是，代表概率所占比例。然似函数是关于参数  $\theta$  的函数，不是概率，对整个参数空间的积分未必等于一。

#### 定义 3.11 (极大然似估计)

可使然似函数取最大值的参数被称为极大然似估计，即

$$\hat{\theta} = \max_{\theta \in \Theta} \mathcal{L}(\theta)$$

**注** 由于对数函数单调递增，最大化然似函数等价于最大化对数然似函数。

若样本来源变量独立同分布，即  $f(x_1, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$ ，则其然似函数和对数然似函数分布可写为：

$$\mathcal{L}(\theta) = \prod_{i=1}^n f(x_i^* | \theta), \quad l(\theta) = \sum_{i=1}^n \log f(x_i^* | \theta)$$

#### 命题 3.2 (极大然似估计的不变性)

设  $\hat{\theta}$  是参数  $\theta$  的极大然似估计，那么对于参数  $\theta$  的任意函数  $\gamma = g(\theta)$ ，其极大然似估计  $\hat{\gamma} = g(\hat{\theta})$

证明

### 3.2.3 贝叶斯估计

贝叶斯估计的基本观点是：任一未知量  $\theta$  都可看作随机变量，可用概率分布  $\pi(\theta)$  描述，称为先验分布；在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来得到关于未知量  $\theta$  的后验分布  $\pi(\theta|\mathbf{X})$ 。任何关于  $\theta$  的统计推断都基于  $\theta$  的后验分布进行。利用后验分布  $\pi(\theta|\mathbf{X})$  估计  $\theta$  有三种常用的方法：

- 使用后验分布的密度函数最大值点作为  $\theta$  的点估计的最大后验估计；
- 使用后验分布的中位数作为  $\theta$  的点估计的后验中位数估计；
- 使用后验分布的均值作为  $\theta$  的点估计的后验期望估计。

用得最多的是后验期望估计，它一般也简称为贝叶斯估计，记为的  $\hat{\theta}_B$ 。

获取后验分布的步骤：

1. 根据总体信息与样本信息确定模型  $p(\mathbf{X}|\theta)$ ，根据先验信息确定参数  $\theta$  的先验分布  $\pi(\theta)$
2. 综合总体信息、样本信息和先验信息得到样本  $\mathbf{X}$  和参数  $\theta$  的联合分布

$$h(\mathbf{X}, \theta) = p(\mathbf{X}|\theta)\pi(\theta)$$

3. 为求后验分布  $\pi(\theta|\mathbf{X}) = \frac{h(\mathbf{X}, \theta)}{m(\mathbf{X})}$ ，先求  $X$  的边际概率函数：

$$m(\mathbf{X}) = \int_{\theta} h(\mathbf{X}, \theta) d\theta = \int_{\theta} p(\mathbf{X}|\theta)\pi(\theta) d\theta$$

4. 得到后验分布

$$\pi(\theta|\mathbf{X}) = \frac{h(\mathbf{X}, \theta)}{m(\mathbf{X})} = \frac{p(\mathbf{X}|\theta)\pi(\theta)}{\int_{\theta} p(\mathbf{X}|\theta)\pi(\theta) d\theta}$$

#### 定义 3.12 (共轭先验分布)

设  $\theta$  是总体参数， $\pi(\theta)$  是其先验分布，若对任意的样本观测值得到的后验分布  $\pi(\theta|\mathbf{X})$  与  $\pi(\theta)$  属于同一个分布族，则称该分布族是  $\theta$  的共轭先验分布（族）。



**例题 3.9** 设某事件  $A$  在一次试验中发生的概率为  $\theta$ ，为估计  $\theta$ ，对试验进行了  $n$  次独立观测，其中事件  $A$  发生了  $X$  次，显然  $X|\theta \sim b(n, \theta)$ ，即

$$P(X=x|\theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x}, \quad x=0, 1, \dots, n$$

假若我们在试验前对事件  $A$  没有什么了解，从对其发生的概率也没有任何信息。在这种场合，贝叶斯本人建议采用“同等无知”的原则，使用区间  $(0, 1)$  上的均匀分布  $U(0, 1)$  作为  $\theta$  的先验分布。贝叶斯的这个建议被后人称为贝叶斯假设。

**解** 先写出  $X$  和  $\theta$  的联合分布

$$h(x, \theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x}, \quad x=0, 1, \dots, n, \quad 0 < \theta < 1$$

然后求  $X$  的边际分布

$$m(x) = \binom{n}{x} \int_0^1 \theta^x (1-\theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}$$

最后求出  $\theta$  的后验分布

$$\pi(\theta|x) = \frac{h(x, \theta)}{m(x)} = \frac{\Gamma(n+2)}{\Gamma(x+1)\Gamma(n-x+1)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, \quad 0 < \theta < 1$$

即  $\theta|x \sim Be(x+1, n-x+1)$ , 故贝塔分布是伯努利试验中成功概率的共轭先验分布。其后验期望估计为

$$\hat{\theta}_B = E(\theta|x) = \frac{x+1}{n+2}$$

**例题 3.10** 设  $x_1, \dots, x_n$  是来自  $N(\mu, \sigma_0^2)$  的一个样本, 其中  $\sigma_0^2$  已知,  $\mu$  未知。假设  $\mu$  的先验分布亦为正态分布  $N(\theta, \tau^2)$ , 其中先验均值  $\theta$  和先验方差  $\tau^2$  均已知, 试求  $\mu$  的贝叶斯估计。

**解** 样本  $\mathbf{X}$  的分布和  $\mu$  的先验分布分别为

$$\begin{aligned} p(\mathbf{X}|\mu) &= (2\pi\sigma_0^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \\ \pi(\mu) &= (2\pi\tau^2)^{-1/2} \exp\left\{-\frac{1}{2\tau^2} (\mu - \theta)^2\right\} \end{aligned}$$

由此可以写出  $\mathbf{X}$  与  $\mu$  的联合分布为

$$h(\mathbf{X}, \mu) = k_1 \cdot \exp\left\{-\frac{1}{2} \left[ \frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{\tau^2} \right] \right\}$$

其中  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ,  $k_1 = (2\pi)^{-(n+1)/2} \tau^{-1} \sigma_0^{-n}$ 。若记

$$A = \frac{n}{\sigma_0^2} + \frac{1}{\tau^2}, \quad B = \frac{n\bar{x}}{\sigma_0^2} + \frac{\theta}{\tau^2}, \quad C = \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\theta^2}{\tau^2}$$

则有

$$\begin{aligned} h(\mathbf{X}, \mu) &= k_1 \exp\left\{-\frac{1}{2} [A\mu^2 - 2B\mu + C]\right\} \\ &= k_1 \exp\left\{-\frac{(\mu - B/A)^2}{2/A} - \frac{1}{2}(C - B^2/A)\right\} \end{aligned}$$

样本的边际密度函数为

$$m(\mathbf{X}) = \int_{-\infty}^{+\infty} h(\mathbf{X}, \mu) d\mu = k_1 \exp\left\{-\frac{1}{2}(C - B^2/A)\right\} (2\pi/A)^{1/2}$$

应用贝叶斯公式即可得到后验分布

$$\pi(\mu|\mathbf{X}) = \frac{h(\mathbf{X}, \mu)}{m(\mathbf{X})} = (2\pi/A)^{-1/2} \exp\left\{-\frac{1}{2/A} (\mu - B/A)^2\right\}$$

这说明在样本给定后,  $\mu$  的后验分布为  $N(B/A, 1/A)$ , 即

$$\mu|\mathbf{X} \sim N\left(\frac{n\bar{x}\tau^2 + \theta\sigma_0^2}{n\tau^2 + \sigma_0^2}, \frac{\sigma_0^2\tau^2}{n\tau^2 + \sigma_0^2}\right)$$

故正态分布是正态总体的共轭先验分布。后验均值即为其贝叶斯估计:

$$\hat{\mu} = \frac{n\tau^2}{n\tau^2 + \sigma_0^2} \bar{x} + \frac{\sigma_0^2}{n\tau^2 + \sigma_0^2} \theta$$

它是样本均值  $\bar{x}$  与先验均值  $\theta$  的加权平均。当总体方差  $\sigma_0^2$  较小或样本量  $n$  较大时, 样本均值  $\bar{x}$  的权重较大; 当先验方差  $\tau^2$  较小时, 先验均值  $\theta$  的权重较大, 这一综合很符合人们的经验。

总体	参数	共轭分布族
$U(\theta - a, \theta + b)$	$\theta$	均匀分布
$B(n, p)$	$p$	Beta 分布
$Poi(\lambda)$	$\lambda$	$Ga(\alpha, \beta) \rightarrow Ga(\alpha + n\bar{x}, \beta + n)$
$N(\mu, \sigma_0^2)$	$\mu$	$N(\theta, \tau^2) \rightarrow N\left(\frac{n\bar{x}\tau^2 + \theta\sigma_0^2}{n\tau^2 + \sigma_0^2}, \frac{\sigma_0^2\tau^2}{n\tau^2 + \sigma_0^2}\right)$
$N(\mu, \sigma^2)$	$\sigma^2$	$IGa(\alpha, \lambda) \rightarrow IGa\left(\alpha + \frac{n}{2}, \beta + \frac{n}{2}(x - \mu)^2\right)$

表 3.1: 常见共轭分布族

### 3.2.4 最小二乘估计

## 3.3 最小方差无偏估计

由于一致最小均方误差估计（定义3.6）一般都不存在，为方便起见，需对估计加一些合理性前置要求，前述无偏性就是一个最常见的合理性要求。

### 3.3.1 最小方差无偏估计

#### 定义 3.13 (一致最小方差无偏估计)

设  $\hat{\theta}$  是  $\theta$  的一个无偏估计，如果对任意一个  $\theta$  的无偏估计  $\tilde{\theta}$ ，在参数空间  $\Theta$  上都有

$$\text{Var}_\theta(\hat{\theta}) \leq \text{Var}_\theta(\tilde{\theta})$$

则称  $\hat{\theta}$  是  $\theta$  的**一致最小方差无偏估计** (uniformly minimum variance unbiased estimation, UMVUE)。 ♣

#### 定理 3.3 (UMVUE 的充要条件)

设  $\mathbf{X} = (\mathbf{x}_1, \Pi, \mathbf{x}_n)$  是来自某总体的一个样本， $\hat{\theta} = \hat{\theta}(\mathbf{X})$  是  $\theta$  的一个无偏估计， $\text{Var}(\hat{\theta}) < +\infty$ . 如果对任意一个满足  $E(\varphi(\mathbf{X})) = \mathbf{0}$  的  $\varphi(\mathbf{X})$ ，都有

$$\text{Cov}_\theta(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta$$

则  $\hat{\theta}$  是  $\theta$  的 UMVUE。 ♡

**证明 充分性：** 对  $\theta$  的任意一个无偏估计  $\tilde{\theta}$

$$\text{Var}(\tilde{\theta}) = E(\tilde{\theta} - \theta)^2 = E[(\tilde{\theta} - \hat{\theta}) + (\hat{\theta} - \theta)]^2$$

代入  $\varphi(\mathbf{X}) = \tilde{\theta} - \hat{\theta}$  得：

$$\text{Var}(\tilde{\theta}) = E(\varphi^2) + \text{Var}(\hat{\theta}) + 2 \text{Cov}(\varphi, \hat{\theta}) \geq \text{Var}(\hat{\theta})$$

**必要性:** 若存在  $\theta_0 \in \Theta$ , 使得  $\text{Cov}_{\theta_0}(\hat{\theta}, \phi(\mathbf{X})) = \mathbf{a} \neq \mathbf{0}$ 。则代入  $\varphi(\mathbf{X}) = \mathbf{b}(\tilde{\theta} - \hat{\theta})$  得:

$$\text{Var}(\tilde{\theta}) = b^2 E(\varphi^2) + \text{Var}(\hat{\theta}) + 2b \text{Cov}(\varphi, \hat{\theta}) = \text{Var}(\hat{\theta}) + b^2 E(\varphi^2) + 2ab$$

再令  $b = -\frac{a}{E(\varphi^2)} \neq 0$ , 则可得  $b^2 E(\varphi^2) + 2ab < 0$ , 即  $\text{Var}(\tilde{\theta}) < \text{Var}(\hat{\theta})$ , 与假设不符。

**例题 3.11** 设  $x_1, \dots, x_n$  是来自指数分布  $\text{Exp}(1/\theta)$  的样本, 对于充分统计量  $T = x_1 + \dots + x_n$ , 由于  $ET = n\theta$ , 所以  $\bar{x} = T/n$  是  $\theta$  的无偏估计。设  $\varphi = \varphi(x_1, \dots, x_n)$  是  $\theta$  的任一无偏估计, 则

$$E\varphi(\mathbf{X}) = \int_0^{+\infty} \cdots \int_0^{+\infty} \varphi(x_1, \dots, x_n) \cdot \prod_{i=1}^n \left\{ \frac{1}{\theta} \cdot e^{-x_i/\theta} \right\} dx_1 \cdots dx_n = 0$$

即

$$\int_0^{+\infty} \cdots \int_0^{+\infty} \varphi(x_1, \dots, x_n) \cdot \exp \left\{ -\frac{n\bar{x}}{\theta} \right\} dx_1 \cdots dx_n = 0$$

两端对  $\theta$  求导, 得

$$\int_0^{+\infty} \cdots \int_0^{+\infty} \varphi(x_1, \dots, x_n) \frac{n\bar{x}}{\theta^2} \cdot \exp \left\{ -\frac{n\bar{x}}{\theta} \right\} dx_1 \cdots dx_n = 0$$

这说明  $E(\bar{x} \cdot \varphi) = 0$ , 从而

$$\text{Cov}(\bar{x}, \varphi) = E(\bar{x} \cdot \varphi) - E(\bar{x}) \cdot E(\varphi) = 0$$

即  $\bar{x}$  是  $\theta$  的 UMVUE.

### 3.3.2 充分性原则

#### 引理 3.1 (Rao–Blackwell 定理)

设  $X$  和  $Y$  是两个随机变量,  $EX = \mu, \text{Var}(X) > 0$ 。用条件期望构造一个新的随机变量  $\varphi(Y) = E(X|Y)$ , 则有

$$E\varphi(Y) = \mu, \text{Var}(\varphi(Y)) \leq \text{Var}(X)$$

其中等号成立的充分必要条件是  $X$  和  $\varphi(Y)$  几乎处处相等。



**证明** 由重期望公式易得

$$E\varphi(Y) = E[E(X|Y)] = EX = \mu$$

将  $\text{Var}(X)$  写成如下的形式:

$$\begin{aligned} \text{Var}(X) &= E[(X - \varphi(Y)) + (\varphi(Y) - \mu)]^2 \\ &= E(X - \varphi(Y))^2 + \text{Var}(\varphi(Y) - \mu) + 2E[(X - \varphi(Y))(\varphi(Y) - \mu)] \end{aligned}$$

由重期望公式

$$\begin{aligned} E[(X - \varphi(Y))(\varphi(Y) - \mu)] &= E\{E[(X - \varphi(Y))(\varphi(Y) - \mu)|Y]\} \\ &= E\{[\varphi(Y) - \mu][E(X|Y) - \varphi(Y)]\} = 0 \end{aligned}$$

由此即有

$$\text{Var}(X) = E(X - \varphi(Y))^2 + \text{Var}(\varphi(Y)) \leq \text{Var}(\varphi(Y))$$

等号成立的充要条件为

$$E[X - \varphi(Y)]^2 = 0$$

即  $X$  和  $\varphi(Y)$  几乎处处相等。

#### 定理 3.4 (充分性原则)

设,  $T = T(x_1, \dots, x_n)$  是  $\theta$  的充分统计量, 则对  $\theta$  的任一无偏估计  $\hat{\theta}$ , 令  $\tilde{\theta} = E(\hat{\theta}|T)$ , 则  $\tilde{\theta}$  也是  $\theta$  的无偏估计, 且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta})$$



**证明** 由于  $T$  是充分统计量, 故而  $\tilde{\theta} = E(\hat{\theta}|T)$  与  $\theta$  无关, 因此它也是一个估计 (统计量)。再将引理3.1取  $X = \hat{\theta}, Y = T$  即可。

**例题 3.12** 设  $x_1, \dots, x_n \stackrel{\text{i.i.d.}}{\sim} b(1, p)$ , 则  $\bar{x}$  (或  $T = n\bar{x}$ ) 是  $p$  的充分统计量. 为估计  $\theta = p^2$ , 可令

$$\hat{\theta}_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1; \\ 0, & \text{其他.} \end{cases}$$

由于

$$E(\hat{\theta}_1) = P(x_1 = 1, x_2 = 1) = p \cdot p = \theta$$

所以,  $\hat{\theta}_1$  是  $\theta$  的无偏估计, 这个估计并不好, 它只使用了两个观测值, 下面我们用 Rao–Blackwell 定理对之加以改进: 求  $\hat{\theta}_1$  关于充分统计量  $T = \sum_{i=1}^n x_i$  的条件期望

$$\begin{aligned} \hat{\theta} &= E(\hat{\theta}_1|T = t) \\ &= P(\hat{\theta}_1 = 1|T = t) \\ &= \frac{P(X_1 = 1, X_2 = 1, T = t)}{P(T = t)} \\ &= \frac{P(X_1 = 1, X_2 = 1, \sum_{i=3}^n X_i = t - 2)}{P(T = t)} \\ &= \frac{p \cdot p \cdot \binom{n-2}{t-2} p^{t-2} (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \binom{n-2}{t-2} / \binom{n}{t} = \frac{t(t-1)}{n(n-1)}, \end{aligned}$$

### 3.3.3 费希尔信息量

#### 定义 3.14

若总体分布  $p(x; \theta), \theta \in \Theta$  满足

1. 参数空间  $\Theta$  是直线上的一个开区间;
2. 支撑  $S = \{x : p(x; \theta) > 0\}$  与  $\Theta$  无关;
3. 导数  $\frac{\partial}{\partial \theta} p(x; \theta)$  对一切  $\theta \in \Theta$  都存在;

4. 对  $p(x; \theta)$ , 积分与微分运算可交换次序, 即

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} p(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial}{\partial \theta} p(x; \theta) dx$$

5. 期望  $E\left[\frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2$  存在,

则称

$$I(\theta) = E\left[\frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2$$

为总体分布的费希尔信息量 (Fisher)。



**注** “ $I(\theta)$  越大” 代表总体分布中包含未知参数  $\theta$  的信息越多。

### 命题 3.3

若总体  $p(x; \theta)$  的费希尔信息量存在, 且存在二阶导数  $\frac{\partial^2}{\partial \theta^2} p(x; \theta) \forall \theta \in \Theta$ , 则

$$I(\theta) = -E\left[\frac{\partial^2}{\partial \theta^2} \ln p(x; \theta)\right]$$



**证明** 由于

$$\int p(x; \theta) dx = 1$$

两边同时对  $\theta$  求偏导得:

$$\frac{\partial}{\partial \theta} \int p(x; \theta) dx = \int \frac{\partial}{\partial \theta} p(x; \theta) dx = \int \frac{\partial}{\partial \theta} \ln p(x; \theta) p(x; \theta) dx = 0$$

再同时对  $\theta$  求偏导得:

$$\int \left[ \frac{\partial^2}{\partial \theta^2} \ln p(x; \theta) \right] p(x; \theta) dx + \int \left[ \frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2 p(x; \theta) dx = 0$$

即

$$E\left[\frac{\partial^2}{\partial \theta^2} \ln p(x; \theta)\right] + I(\theta) = 0$$

### 命题 3.4

对于总体分布  $p(x; \theta)$ , 若其参数  $\theta$  的费希尔信息量存在且为  $I(\theta)$ , 则对于参数的函数  $\tau(\theta)$  的费希尔信息量为

$$I(\tau(\theta)) = E\left[\frac{\partial}{\partial \tau(\theta)} \ln p(x; \theta)\right]^2 = \frac{I(\theta)}{[\tau'(\theta)]^2}$$



**证明**

$$\begin{aligned} I(\tau(\theta)) &= E\left[\frac{\partial}{\partial \tau(\theta)} \ln p(x; \theta)\right]^2 = E\left[\frac{\partial \theta}{\partial \tau(\theta)} \frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2 \\ &= \left[\frac{\partial \theta}{\partial \tau(\theta)}\right]^2 E\left[\frac{\partial}{\partial \theta} \ln p(x; \theta)\right]^2 = \frac{I(\theta)}{[\tau'(\theta)]^2} \end{aligned}$$

### 3.3.4 Cramer-Rao 不等式

#### 定理 3.5 (Cramer-Rao 不等式)

设总体分布  $p(x; \theta)$  存在费希尔统计量。若对  $g(\theta)$  的任一个无偏估计  $T$ ,

$$g(\theta) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, \dots, x_n) \prod_{i=1}^n p(x_i; \theta) dx_1 \cdots dx_n, \quad \forall \theta \in \Theta$$

的微商  $g'(\theta) = \frac{dg(\theta)}{d\theta}$  存在, 并且可在积分号下进行, 即

$$\begin{aligned} g'(\theta) &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left( \prod_{i=1}^n p(x_i; \theta) \right) dx_1 \cdots dx_n \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, \dots, x_n) \left[ \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n p(x_i; \theta) \right] \prod_{i=1}^n p(x_i; \theta) dx_1 \cdots dx_n \end{aligned}$$

对离散总体, 则将上述积分改为求和符号后, 等式仍然成立. 则有

$$\text{Var}(T) \geq \frac{1}{nI(g(\theta))}$$

特别地, 对  $\theta$  的无偏估计  $\hat{\theta}$ , 有  $\text{Var}(\hat{\theta}) \geq (nI(\theta))^{-1}$ .



**证明** 以连续总体为例: 由于

$$\int p(x_i; \theta) dx_i = 1$$

两边同时对  $\theta$  求偏导, 由于积分与微分可交换次序, 于是有:

$$\begin{aligned} \frac{\partial}{\partial \theta} \int p(x_i; \theta) dx_i &= \int \frac{\partial}{\partial \theta} p(x_i; \theta) dx_i = \int \frac{\partial}{\partial \theta} \ln p(x_i; \theta) p(x_i; \theta) dx_i \\ &= E \left[ \frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right] = 0 \end{aligned}$$

记

$$Z = \frac{\partial}{\partial \theta} \ln \prod_{i=1}^n p(x_i; \theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln p(x_i; \theta)$$

则

$$E(Z) = \sum_{i=1}^n E \left[ \frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right] = 0$$

从而

$$\begin{aligned} \text{Var}(Z) &= \sum_{i=1}^n \text{Var} \left( \frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right) \\ &= \sum_{i=1}^n E \left[ \left( \frac{\partial}{\partial \theta} \ln p(x_i; \theta) \right)^2 \right] = nI(\theta) \end{aligned}$$

又由

$$g'(\theta) = E(T \cdot Z) = E((T - g(\theta)) \cdot Z)$$

据施瓦茨不等式，有

$$\left[ g'(\theta) \right]^2 \leq E[(T - g(\theta))^2] \cdot E(Z^2) = \text{Var}(T) \text{Var}(Z)$$

关于离散总体可类似证明。

### 定义 3.15 (CR 下界)

称  $\frac{1}{nI(g(\theta))}$  为  $g(\theta)$  的无偏估计的方差的 **C-R 下界**，简称  $g(\theta)$  的 CR 下界。若估计式的方差达到 C-R 下界，则称其为参数的**有效估计**，即 UMVUE。

## 错题记录

1. (茆 6.1.14) 设  $x_1, \dots, x_n$  是来自二点分布  $b(1, p)$  的一个样本，证明  $\frac{1}{p}$  的无偏估计不存在。
2. (茆 6.2.3(2)) 设总体分布列为  $P(X = k) = (k-1)\theta^2(1-\theta)^{k-2}$ ,  $k = 2, 3, \dots, 0 < \theta < 1$  如下,  $x_1, x_2, \dots, x_n$ ，试求未知参数的矩估计。
3. (茆 6.4.3)
4. (茆 6.4.4)
5. (茆 6.4.5)
6. (茆 6.4.6)
7. (茆 6.4.9)
8. (茆 6.4.11)
9. (茆 6.4.12)
10. (茆 6.4.13)
11. (茆 6.4.14)
12. (茆 6.4.16-20)
13. (茆 6.5.12-16)